## INTELIGENCIA ARTIFICIAL



Sistemas Expertos Probabilísticos, Inferencia Bayesiana y Redes Bayesianas

1

### **Redes Bayesianas**



Inteligencia Artificia

2

### **Redes Bayesianas**



- Modelo gráfico que codifica relaciones probabilísticas entre las variables de interés.
- Ventajas para el análisis de datos:
  - Como el modelo codifica las dependencias entre variables, fácilmente maneja situaciones en que faltan algunos datos
  - La red puede ser usada para aprender relaciones causales y por tanto para obtener conocimiento del dominio del problema y predecir consecuencias de una intervención.
  - Es ideal para combinar conocimiento previo y datos
- Métodos para aprender redes bayesianas a partir de los datos

Inteligencia Artificial

nie Antiliaiet

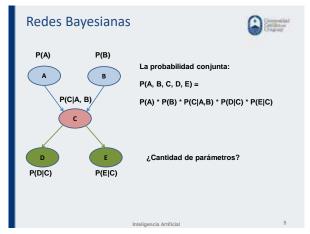
### Red Bayesiana



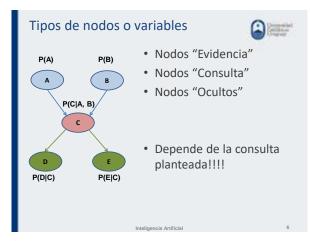
- Una red bayesiana es un modelo gráfico
- Refleja los estados de un universo modelado y describe cómo esos estados se relacionan mediante probabilidades
- Los posibles estados del modelo representan todos los mundos que pueden existir, todas las formas posibles en que los estados pueden ser configurados.
- Algunos estados tienden a ocurrir con mayor frecuencia cuando otros están presentes. Ej: si Ud. está enfermo, las probabilidades de que tenga fiebre son mayores.

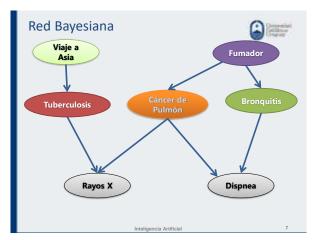
Inteligencia Artificial

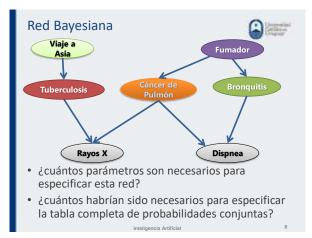
4



5







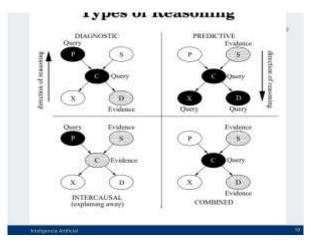
8

### Redes bayesianas y modelado causal

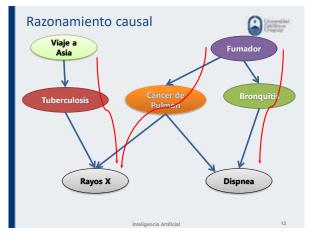


- · Construir la red desde causa a efecto
- Empezar con los nodos que representan causas básicas independientes
- Luego modelar los nodos influenciados por los anteriores...
- Y así sucesivamente hasta las hojas...
- Es útil tener una "historia" en mente...
- A veces es difícil determinar qué es causa y qué es efecto...

atalisanaja Astiliaja!



# Tipos de razonamiento Razonamiento causal Razonamiento evidencial Razonamiento intercausal



### TA8 – ej 1



- · Con el modelo "Asia",
  - Observar las probabilidades de las enfermedades
  - A) el paciente estuvo en Asia
    - Usando el Case Manager representar esta situación
    - Analizar los resultados para el diagnóstico y evidencias esperados
  - B) el paciente FUMA (pero no sabemos si visitó Asia)
  - C) el paciente FUMA Y estuvo en Asia

13

13



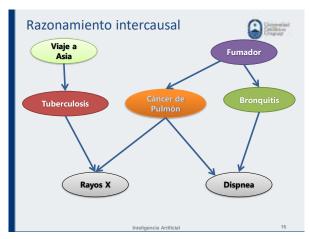
14

### TA8 – ej 2



- Con el modelo "Asia",
  - Observar las probabilidades de las enfermedades
  - El paciente indica que tiene dificultades para respirar normalmente
  - en un nuevo caso del Case Manager 2 representar esta situación
  - Analizar los resultados para el diagnóstico y el efecto sobre los factores de riesgo también

Inteligencie Autiliaiel



# TA8 – ej 3 Ej. Razonamiento intercausal



- · Con el modelo "Asia2",
  - Ahora el médico indica una placa de tórax, cuyo resultado da positivo ("anormal").
  - en Case Manager representar esta situación
  - Analizar los resultados para el diagnóstico
  - ¿cuál es el diagnóstico más probable ahora?

Inteligencia Artificial

......

**17** 

### TA 6



- Discusión sobre estructuras
- Desarrollo de las tablas de probabilidades condicionales
- Pruebas del modelo: preguntas Ejercicio 2 (usando el Case Manager)

Inteligencia Artificial

### CDT



- Fenton Managing Risk in the Modern World: Applications of Bayesian Networks,
  - Box 6 pag 17 continuous variables
  - Box 7 pag 19 nodes with many parents
- Fenton Risk assessment and decision analysis with Bayesian networks
  - Cap 8 Building and eliciting Node Probability tables

Inteligencia Artificial

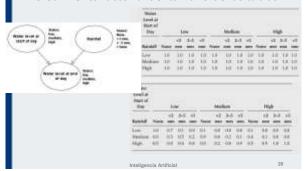
19

19

## Construyendo las tablas de probabilidades condicionales de los nodos de la red



• Crecimiento factorial del tamaño de las tablas



20

### Tipos de nodos en GeNIe 3.0



- Chance
  - General, NoisyMax, NoisyAdder (ver Canonical models)
- Deterministic
  - Constantes
  - Expresiones en función de los padres
- Equation (pueden tomar valores continuos)
- Submodel
- Ver manual de GeNIe 3.0, sección 5.3
- Aprovechando estas alternativas, mejorar el modelo del TA6 y ver cómo se responden las preguntas

Intoligonoia Artificial

### Modelos lesión



- 1 er version, estudiante lesión
- 2da incluimos deporte
- Observar las condiciones limitantes

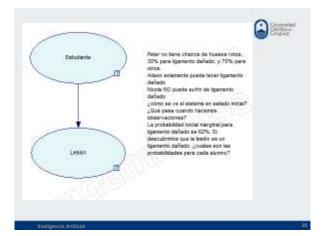
22

### Nodos deterministas y funcionales



- Abrir el modelo "lesion1"
- El nodo "estudiante" representa los diferentes estudiantes que participant en deportes
- Observar sus probabilidades a priori
- El nodo "lesion" es condicional en "estudiante", asi que tenemos que especificar cada probabilidad de herida en función del estudiante. Observar las probabilidades.
- Ejecuta el modelo y observa qué pasa para diferentes estudiantes

28



### Escenarios con restricciones



- Peter no tiene chance de huesos rotos, 30% para ligamento dañado, y 70% para otros.
- Alison solamente puede tener ligamento dañado
- Nicole NO puede sufrir de ligamento dañado
- ¿cómo se ve el sistema en estado inicial?
- ¿Qué pasa cuando hacemos observaciones?
  - La probabilidad inicial marginal para ligamento dañado es 62%. Si descubrimos que la lesión es un ligamento dañado, ¿cuáles son las probabilidades para cada alumno?

Inteligencia Artificial

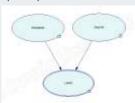
30

30

### Nodos deterministas y ecuaciones



 Supongamos que deseamos extender el modelo para incluir el impacto de cada deporte en particular en las heridas que se pueden tener



 Visualizar la red "LESION2", y observar la tabla de "lesion"

Inteligencia Artificial

31

### 31

### Nodos deterministas



- Simplifican operaciones muy básicas en función de los padres, o constantes
- Ejercicio: implementar una red que represent la operacion "XOR" sobre dos variables booleanas X e Y
- OR
- AND
- TA9 Ejercicio 1
- Observar el uso de OR en modelo TA6

Inteligencia Artificial

### Nodos deterministas



- Abrir la red Asia que temenos, y salvarla como Asia2
- Agregar un nodo intermedio determinista "Tuberculosis or Cancer"
- Ejecutar la red, y
  - Evidencia "disnea", observar cómo evolucionan las enfermedades – y el nodo OR en particular –
  - Luego indicar que el paciente es NO fumador
  - A continuación, sabemos que ha estado en ASIA
  - Por ultimo, el medico indica una placa, y ésta da positivo

Inteligencia Artificial

33

33

### Nodos deterministas

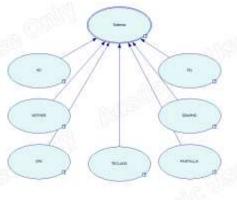


- Simplifican operaciones muy básicas en función de los padres, o constantes
- Ejercicio: implementar una red que represent la operacion "XOR" sobre dos variables booleanas X e Y
- OR
- AND
- TA 9 ej 2 EJERCICIO: RED "SYSTEM"

Inteligencia Artificial

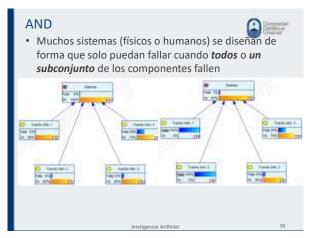
34

34



Inteligencia Artificial

35



# Funcion booleana con Nodos Equation • En vez de escribir las probabilidades podemos usar una ecuación... If IA == "True" || || == "True", "True", "False"| If (Tuberculosis == "True" || Cancer == "True", "True", "False") • Hacer el cambio en la red y Volver a ejecutar los pasos anteriores

37

### Modelos Probabilísticos Canónicos



- Los modelos gráficos probabilísticos requieren de la especificación de muchas distribuciones de probabilidades conjuntas
- El tamaño de las tablas de probabilidades condicionales crece exponencialmente con el número de padres de la variable considerada
- Los parámetros numéricos se obtienen de bases de datos o son evaluados por expertos humanos.

neia Artificial

### Modelos Probabilísticos Canónicos



- Modelos canónicos una forma de reducir la complejidad
- "canónico" unidad elemental utilizada en modelos más complejos
- Representa una relación probabilística de la forma P(y|x) que involucra una cantidad finite de variables (familia) {Y, X<sub>1</sub>, X<sub>2</sub>...X<sub>n</sub>} en donde el nodo Y es llamado el hijo y los X<sub>i</sub> son los padres



39

39

### Modelos Probabilísticos Canónicos



- Distintos modelos canónicos pueden coexistir en una red bayesiana
  - Ejemplo, en redes causales que representan casos del mundo real, es común tener varias familias con modelos OR/MAX, algunas con AND y el resto comunes (sus CPT deben darse)
- Útiles porque:
  - Simplifican la construcción de los modelos (ing. del conocimiento)
  - Ahorran espacio y tiempo de cálculo
  - Corresponden a patrones causales que pueden explicarse al usuario

nteligencia Artificial

40

40

### Modelos Probabilísticos Canónicos



Modelos Deterministas

$$P(y|\mathbf{x}) = \begin{cases} 1 & \text{if } y = f(\mathbf{x}) \\ 0 & \text{otherwise} \end{cases}$$

	Type of variables	Name	Definition
logásali	Boolean	NOT OR AND XOB r-out-of-si threshold	$y \Longleftrightarrow \neg s$ $y \Longleftrightarrow x_1 \lor \lor x_n$ $y \Longleftrightarrow s_1 \lor \lor x_n$ $y \Longleftrightarrow \inf(I_{s}(\mathbf{x})) \equiv 1$ $y \Longleftrightarrow \inf(I_{s}(\mathbf{x})) = s$ $y \Longleftrightarrow \inf(I_{s}(\mathbf{x})) \geq s$
algebraic	untical	MINUS INV MAX MIN ADD arrouge discrete average listore resulting	$\begin{array}{l} y = -x \\ y \equiv x_{\min} - x \\ y = \max\{x_1, \dots, x_k\} \\ y = \min\{x_1, \dots, x_k\} \\ y = x_1 + \dots + x_n \\ y \equiv \left[ x_1 + \dots + x_n \right] \\ y \equiv \left[ \left[ x_1 + \dots + x_n \right] \right] \\ y \equiv x_1 + x_1 + x_2 + x_3 \\ y \equiv x_1 + x_2 + x_3 + x_4 \\ y \equiv x_1 + x_2 + x_3 + x_4 \\ y \equiv x_1 + x_2 + x_3 + x_4 \\ y \equiv x_1 + x_2 + x_3 + x_4 \\ y \equiv x_1 + x_2 + x_3 + x_4 \\ y \equiv x_1 + x_2 + x_3 + x_4 \\ y \equiv x_1 + x_2 + x_3 + x_4 \\ y \equiv x_1 + x_2 + x_3 + x_3 \\ y \equiv x_1 + x_2 + x_3 + x_3 \\ y \equiv x_1 + x_2 + x_3 + x_3 $

# Modelos Probabilísticos Canónicos

Modelos Deterministas booleanos

Function	CP	T		
NOT	P(+y x)	+x -	-w 1	
OR	$\frac{P(+y x_1,x_2)}{+x_2}$	+x1	¬α <sub>1</sub>	
	$P(+y x_1, x_2)$	+x1		
AND	+x2	0	0	
XOR	$\frac{P(+y x_1,x_2)}{+x_2}$	+x <sub>1</sub>	7/1	
	Tay	1	0	
	ппепуепсы м	runciai		

42

# Modelos IIC – independencia de influencia causal



- Las relaciones deterministas no son muy comunes en la práctica (las interacciones típicas en el mundo real son inciertas.
- Dos tipos:
  - "ruidosos" "noisy"
  - " con fugas " " leaky"

Intoligonoia Artificial

43

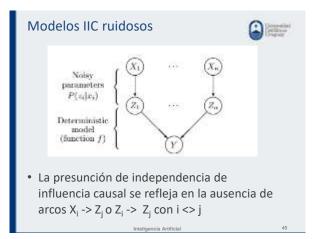
### Modelos IIC ruidosos

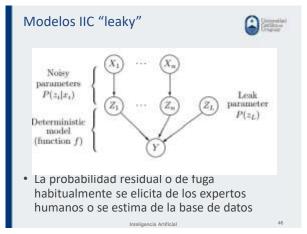


- Se construyen a partir de modelos deterministas, introduciendo variables auxiliaries {Z<sub>1</sub>, Z<sub>2</sub>...Z<sub>n</sub>} (familia)
- Y es una función determinista de las Z,
- el valor de cada Z<sub>i</sub> depende probabilísticamente de X<sub>i</sub> como se modela en su CPT P(z<sub>i</sub>|x<sub>i</sub>)

$$P(y|\mathbf{x}) = \sum_{\mathbf{z}} P(y|\mathbf{z}) \cdot P(\mathbf{z}|\mathbf{x}) \; .$$

Inteligencia Artificial





# Modelos canónicos simples • Los modelos IIC requieren de una tabla P() para cada arco – el número de parámetros es proporcional al número de padres. | Determinate | Padres | Padres

Inteligencia Artificial

### Modelos OR/MAX



- Noisy or/max,
- Noisy and/min,
- · Noisy adder (ponderado)

48

### Box 8.7 General Definition of the NoisyOR Function

Suppose there are  $\sigma$  cannot factors,  $X_s = X_s$  of a condition,  $\Gamma$ . Suppose also that we can assign a probability value for  $\Gamma$  being true when one and only one  $X_s$  is true, and all causes other than  $X_s$  are false. Then the NewyOR function can be used. Formally it is defined as

$$NeiryOR(X_1,r_1,X_2,r_2,\ldots,X_n,r_n,l)$$

where for each  $i \in_i = P(T = \max \mid X_i = \max , X_j = \text{false for each } j \neq i)$  is the probability of the condition being was if and only if that sole cannot factor is true.

The look factor. It is the probability that Y will be true when all of the cannot factors are false:

$$I = P(T = mor) \; X_1 = false, X_2 = false \qquad \qquad , X_n = false)$$

In using the NoisyOR we are assuming we can consider each cause independently of the others in terms of their effects. Formally, we generate the NPT for the NoisyOR function using

 $P(Y=Tine(X_1,...,X_n))$ 

 $=1-\prod_{i=1}^n \left[ (1-P(i)+True)(I_i+True)(1-P(i)) \right]$ 

This "independent cannot influence" to a key assumption in the use of the NeisyOR function.

49

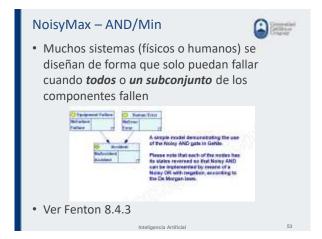
### noisyMax



- Revisar los ejemplos de las redes GenNIe:
  - NoisyMax
  - NoisyAND
  - NoisyAdder
- TA 10 ataque cardiaco

# NoisyOR – TA10 • Crear red "ataque al corazón" • Observar el uso del NoisyOR • Experimentar con diferentes combinaciones de factores





## Redes BN2O • Red bayesiana de 2 capas - Capa superior representa las causas (ej enfermedades) Capa inferior las evidencias (ej. síntomas) · Todas las variables son binarias • Los nodos de la capa inferior se modelan todos con NoisyOR

54

### Aplicación de redes BN2O



• TA11 - meningitis

55

### Funcionalidades para Diagnóstico



- una de las aplicaciones más exitosas de las redes bayesianas
- Las redes bayesianas pueden realizar la fusión de observaciones
- Posibles comportamientos defectuosos y posibles pruebas de diagnóstico
- El modelo captura cómo los posibles defectos del sistema (fallas) pueden manifestarse (evidencias, tests, síntomas)
- Produce lista ordenada de los defectos más probables y lista ordenada de las pruebas más informativas y rentables







# Propiedades de los nodos para diagnóstico



- Hay que especificar las propiedades roles y estados
- Ej: estado de componente electrónico
  - Falla
  - Ok
- Síntomas o mensajes de error:
  - Presente
  - Ausente
- Los arcos habitualmente representan relaciones causales (ej: gripe –fault- causa fiebre –observation-)

nteligencia Artificial

60

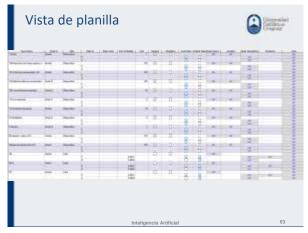


61

# Propiedades de los nodos para diagnóstico



- Fault
  - Ranked
- Observation
  - Ranked
  - Mandatory
- Cost of observation







### TA 11 – EJ2



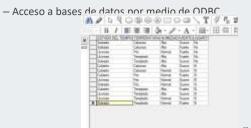
- Abrir la red de diagnóstico de meningitis de los ejercicios anteriores
- Habilitar el diagnóstico
- Configurar los nodos en forma acorde
- Correr los diagnósticos y observar qué nos da la Ventana de diagnóstico

66

### Aprendizaje de redes bayesianas



- Acceso a datos
  - Archivos de texto, \*.txt, \*.csv
  - La primera fila contiene los ID de las variables
  - Formato GeNIe nativo .dat



67

### Aprendizaje de redes bayesianas

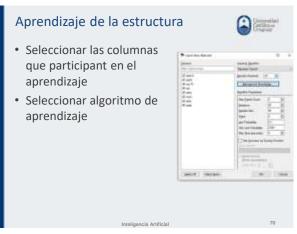


Funcionalidades para análisis y preparación o los datos

- Explorar....
- Aprendizaje de estructura de la red
- Aprendizaje de parámetros de la red
- Knowledge editor

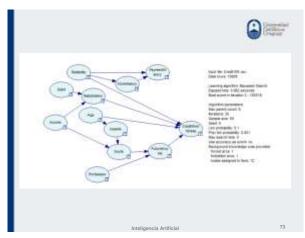
S inches	- 0 +
Said	states butter
(the section)	Renal here
ar or town on yours.	Section 5 1
214900	Management.
ST ST COUNTY	Section Section 1
	Statestine A B
P-11-	mindge below
-	DESIGNATION OF
100	ter band have based that thereight have
20.00	
100	ing.
38	ini m
7.5	CHAIN CO.
3.4	rise .
(6)	doe)
>	
Secret la Co	Man .
Contract in	
75	



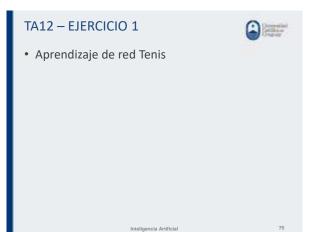


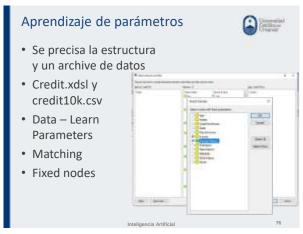
# Propiedades generales de los algoritmos de aprendizaje de estructura Todos son capaces de aprender la estructura cuando todas las variables son categóricas El algoritmo PC permite aprender la estructura cuando todas las variables son continuas y su distribución conjunta es normal multivariada Ninguno admite combinaciones Si alguna variable es discreta, hay que discretizar todas las que sean continuas Ninguno (excepto Naive Bayes) puede aprender cuando hay valores faltantes en los datos

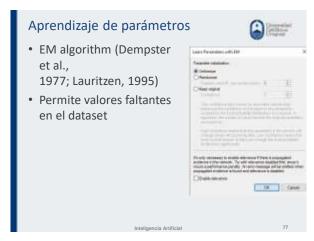












### TA12 - EJERCICIO 2



- Aprendizaje de parámetros de red "credit10k"
- Archivos:
  - Credit.xdsl y
  - credit10k.csv

Inteligencia Artificial

78

**78** 

### Sistemas Expertos basados en probabilidades, consideraciones



Inteligencia Artificia

**79** 

### SEBP - Base de Conocimiento



- Consiste en un conjunto de variables, {X<sub>1</sub>,...,X<sub>n</sub>}, y una función de probabilidad conjunta definida sobre ellas, p(x<sub>1</sub>,...,x<sub>n</sub>).
- Modelo más general: probabilidad conjunta. Asignar un valor numérico (parámetro) a cada una de las posibles combinaciones de valores de las variables.
- Gran número de parámetros!!!! Para *n* variables binarias, 2<sup>n</sup> parámetros!
- Muchos subconjuntos de variables pueden ser independientes o condicionalmente independientes

Inteligencia Artificial

### Base de Conocimiento



- Modelo de Sintomas Dependientes (MSD).
- Modelo de Sintomas Independientes (MSI).
- Modelo de Sintomas Relevantes Independientes (MSRI).
- El Modelo de Sintomas Relevantes Dependientes (MSRD).

Inteligencia Artificial

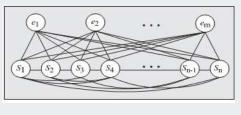
0.4

81

## Modelo de Síntomas Dependientes (MSD)



• Síntomas son dependientes, enfermedades independientes entre sí, dados los síntomas



Inteligencia Artificial

82

# Modelo de Síntomas Dependientes (MSD)



$$p(e_i|s_1,...,s_n) = \frac{p(e_i, s_1,...,s_n)}{p(s_1,...,s_n)}$$

$$= \frac{p(e_i)p(s_1,...,s_n|e_i)}{p(s_1,...,s_n)}$$

$$\propto p(e_i)p(s_1,...,s_n|e_i).$$

• Se requieren m(2<sup>n</sup>-1) parámetros!!!

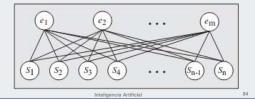
Inteligencia Artificial

### Modelo de Síntomas Independientes (MSI)



• Simplificación: asumir que, para una enfermedad dada, los síntomas son condicionalmente independientes entre sí

$$p(s_1,...,s_n|e_i) = \prod_{j=1}^n p(s_j|e_i).$$



84

### Modelo de Síntomas Independientes (MSI)



$$p(e_i|s_1, \dots, s_n) = \frac{p(e_i)p(s_1, \dots, s_n|e_i)}{p(s_1, \dots, s_n)}$$
$$= \frac{p(e_i) \prod_{j=1}^n p(s_j|e_i)}{p(s_1, \dots, s_n)}$$
$$\propto p(e_i) \prod_{j=1}^n p(s_j|e_i).$$

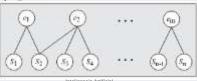
número total de parámetros es m(n+1)−1

85

### Modelo de Síntomas Relevantes Independientes (MSRI)



- · Cada enfermedad tiene un número reducido de síntomas relevantes
- Para cada valor e, de la enfermedad E se seleccionan algunos síntomas relevantes S<sub>1</sub>,...,S<sub>r</sub> (pocos frente al total de síntomas) y los restantes se suponen independientes para ese valor



### Modelo de Síntomas Relevantes Independientes (MSRI)



• Número de parámetros:

$$m-1+n-a+\sum_{i=1}^m r_i,$$

 r<sub>i</sub>: número de síntomas relevantes para la enfermedad e<sub>i</sub> y a es el número de síntomas que son relevantes para todas las enfermedades.

Inteligencia Artificial

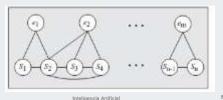
87

87

### El Modelo de Síntomas Relevantes Dependientes (MSRD)



- MSRI es poco realista, ya que los síntomas asociados a ciertas enfermedades suelen producirse en grupos o síndromes.
- Poco factible que los síntomas relevantes sean independientes



88

### El Modelo de Síntomas Relevantes Dependientes (MSRD)



• Número total de parámetros

$$m-1+n-a+\sum_{i=1}^{m}(2^{r_i}-1)=n-1-a+\sum_{i=1}^{m}2^{r_i}.$$

Inteligencie Autificial

### Comparación de modelos



 m = 100 enfermedades, n = 200 síntomas, r = 10 síntomas relevantes por enfermedad

	Número de parámetros			
Modelo	Fórmula	Valor		
MSD	$m2^{n} - 1$	$> 10^{62}$		
MSI	m(n + 1) - 1	20,099		
MSRI	m(r+1) + n - 1	1,299		
MSRD	$m2^r + n - 1$	102,599		

Inteligencia Artificial

90

90

### SEBP - Motor de inferencia



- Dos tipos de conocimiento:
  - El conocimiento, variables y probabilidades asociadas necesarias para construir la función de probabilidad conjunta. Se almacena en la base de conocimiento.
  - 2. Los datos, conjunto de valores de algunas variables (ej: síntomas) conocidos. "Evidencia", se almacena en la memoria de trabajo.
- El motor de inferencia utiliza ambos para responder a preguntas hechas por el usuario.

Intoligonoia Artificial

91

91

### SEBP - Motor de inferencia



 Una de las tareas del motor de inferencia es calcular las probabilidades condicionales de diferentes enfermedades cuando se conocen nuevos síntomas o datos. Actualiza las probabilidades condicionales:

$$p(e_i|s_1,...,s_k) = \frac{p(e_i, s_1,...,s_k)}{p(s_1,...,s_k)}; i = 1,...,m,$$

- para todos los posibles valores de los síntomas
- el teorema de Bayes se utiliza para calcular con facilidad las probabilidades "a posteriori"

Inteligencie Autificial

### Inferencia bayesiana



- El motor de inferencia aplica iterativamente el Teorema de Bayes a partir de las probabilidades de las premisas, para derivar el consecuente
- La base de conocimiento consiste en un conjunto de probabilidades que deben ser relevadas

93

### Meningitis Aguda Supurada La Enfermedad



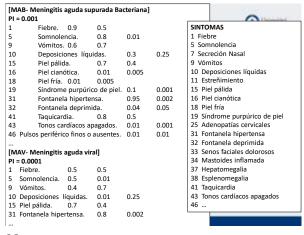
- Características
- Síntomas y Signos (más de 80 considerados)
- Diagnósticos diferenciales (8)
- · Proceso de diagnóstico y dificultades asociadas

94

### Meningitis Aguda Supurada



- Síntomas o Interrogatorio
- Examen físico de piel y mucosas. Examen físico bucofaríngeo
- Examen físico Linfoganglionar
- Examen físico de Cráneo y Cara
- Examen físico de abdomen
- Examen físico cardiovascular
- Examen físico Pleuropulmonar
- Examen físico de ojos y nariz
- Examen Físico Neurológico
- Signos meníngeos
- · Análisis LCR
- · Análisis de sangre
- Hemocultivo
- Análisis del Líquido Céfalo Raquídeo Exudado Faríngeo
  - Otros síntomas, signos o resultados de análisis
  - Tomografía computada
  - Ecografía Transfontanelar



### Diagnósticos diferenciales



- · Meningitis aguda viral
- Meningitis tuberculosa
- Encefalitis
- Absceso cerebral
- Meningismo
- · Reacción meníngea de vecindad
- · Hemorragia meníngea
- Tumor cerebral

asociadas

Inteligencia Artificial

Artificial

97

### Meningitis Aguda Supurada



- Proceso de diagnóstico y dificultades
  - Necesidad de llegar a un diagnóstico preciso en un tiempo limitado
  - Prescripción de maniobras o análisis de laboratorio más complicados (riesgo, costo)
  - Incertidumbre e imprecisión en la apreciación de síntomas y signos

Inteligencia Artificial

9.8

### SEDMAS - probabilidades e inferencia



- Sistema Experto de Diagnóstico de Meningitis Aguda Bacteriana
  - Motor de inferencia bayesiano
  - Aplicación iterativa del Teorema de Bayes
- Base de conocimiento
  - Probabilidades de enfermedades
  - Probabilidades de síntomas y signos
- ¿Aprendizaje?

Inteligencia Artificial

00

99

## SEDMAS – probabilidaes y ciclo de inferencia



PI

$$-PS$$
  $P(H/E) = \frac{PS*PI}{PS*PI + PN*(1-PI)}$ 

- Inicio: P(H) = PI para cada una de las enfermedades,
- Iterativamente se calcula P(H/E) de acuerdo a cada dato, sustituyendo la probabilidad a priori P(H) por P(H/E).

Inteligencia Artificial

100

### 100

### Referencias:



- "Construcción de Sistema Experto de Diagnóstico de Meningitis", Ernesto Ocampo Edye et. al., CISIC 2003, Salamanca, España
- "Comparing Bayesian inference and casebased reasoning as support techniques in the diagnosis of Acute Bacterial Meningitis", Ernesto Ocampo Edye et. al., Expert Systems with Applications, Nº38, 2011, Elsevier.

(ambos disponibles en la webasignatura del curso)

Inteligencia Artificial